



INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

Gestión de Producción de Bienes y Servicios

Unidad 3: Pronóstico y Planificación de Operaciones

Sebastián Dávila, Ph.D.

Cristian Durán, Ph.D.

Luis Rojo-González, Ph.D.



Recorrido general

El curso parte mirando la operación como un sistema, luego aborda mejora y calidad, y finalmente baja a decisiones cuantitativas de pronóstico, planificación, producción, inventario y secuenciamiento.

U	Unidad	Pregunta de trabajo
1	Conceptos básicos de la Gestión de Operaciones	Operación como sistema de transformación; bienes, servicios, estrategia, procesos y cadena de suministro.
2	Calidad	Mejora de procesos, herramientas básicas, variabilidad, control estadístico, capacidad y muestreo.
3	Pronóstico y Planificación de Operaciones	Demanda futura, incertidumbre, evaluación de modelos y uso del pronóstico para decidir.
4	Producción e Inventario	Planificación agregada, lot-sizing, inventarios, capacidad y costos de producción.
5	Secuenciamiento	Programación operativa de trabajos, máquinas, restricciones y criterios de desempeño.

Sistema y estrategia → calidad y mejora → demanda futura → plan de producción → programación operativa.

Resultados de aprendizaje



Al finalizar la unidad, el estudiante podrá


- ▶ Distinguir pronóstico, objetivo, presupuesto y plan.
- ▶ Diagnosticar tendencia, estacionalidad, ciclos, atípicos, faltantes y quiebres.
- ▶ Aplicar métodos clásicos (naive → ETS) e interpretar SARIMA.
- ▶ Evaluar con validación temporal y métricas pertinentes, evitando *leakage*.
- ▶ Pronosticar sobre jerarquías de productos y conectar con inventarios y S&OP.

Mapa

1. Fundamentos aplicados
2. Métodos clásicos e intro SARIMA
3. Evaluación y validación
4. Jerarquías y planificación

Idea clave

Formular el problema *antes* de elegir el modelo.




Problema motivador




Una jefatura de operaciones pregunta


“¿Cuántas unidades de cada familia debemos tener el próximo trimestre, y con qué confianza?”



- ▶ No es una sola pregunta: hay **muchas series** (categorías, familias, SKU).
- ▶ El error tiene **costo asimétrico**: quebrar $\neq$ sobre-stockear.
- ▶ La respuesta alimenta **compras, producción y capacidad**.




Un pronóstico no es un fin en sí mismo



Idea clave

El pronóstico es un **insumo** para una decisión con costo, no el producto final. Su calidad se juzga por la decisión que habilita.



Cuatro conceptos que se confunden




Distinciones esenciales

- ▶ **Pronóstico:** lo que *esperamos* que ocurra dado lo que sabemos (probabilístico).
- ▶ **Objetivo (meta):** lo que *queremos* lograr (aspiracional).
- ▶ **Presupuesto:** recursos *comprometidos* bajo un supuesto de demanda.
- ▶ **Plan:** lo que *haremos* (decisiones), condicionado al pronóstico y a restricciones.

Idea clave

Solo el **pronóstico** pretende ser inesgado. Los otros tres incorporan voluntad, compromiso o restricciones.



Qué pasa si el pronóstico se fija igual a la meta



Cuidado


Si comercial fija la meta 15 % sobre el año previo y “ajusta el pronóstico a la meta”, se planifican compras y capacidad para una demanda que probablemente **no ocurrirá**.

Consecuencia

- ▶ Exceso de inventario sistemático.
- ▶ Se destruye la señal objetiva.
- ▶ S&OP discute deseos, no evidencia.

Implicancia operacional

La meta se gestiona con *decisiones* (promoción, precio), no contaminando el pronóstico.



Tres decisiones *previas* al modelo




Horizonte
¿para cuándo?

Frecuencia
¿cada cuánto?

Agregación
¿a qué nivel?

Idea clave

Estas tres decisiones se toman **antes** de elegir un modelo, y las determina la *decisión operacional*, no la comodidad de los datos.



Horizonte de pronóstico





El horizonte útil lo fija la decisión


- ▶ **Operativo** (días–semanas): reposición.
- ▶ **Táctico** (meses): S&OP, capacidad.
- ▶ **Estratégico** (años): inversiones.

Implicancia operacional

El *lead time* de reposición fija el **horizonte mínimo** relevante: no sirve pronosticar a 1 semana si reponer toma 6.



Frecuencia de los datos




Diaria, semanal, mensual


- Más fina: capta detalle, pero más ruido y más ceros.
- Más gruesa: más estable, pero pierde granularidad.

Cuidado

La frecuencia debe coincidir con la **frecuencia de la decisión**. Pronosticar diario lo que se decide semanal agrega ruido sin valor.




Nivel de agregación: agregar estabiliza




- ▶ El **SKU** es ruidoso; la **familia** (suma) es estable.
- ▶ Agregar reduce el ruido *relativo*...
- ▶ ... pero **oculta** la heterogeneidad interna.

Idea clave

Elegir el nivel es un compromiso entre **estabilidad** (arriba) y **granularidad de decisión** (abajo).




Anatomía de una serie de tiempo




Idea clave

Identificar las componentes **orienta la familia de modelos**: no es un adorno, es el primer paso del diagnóstico.



Una serie es un *proceso estocástico*, no una muestra i.i.d.



Qué significa

Cada y_t es una **variable aleatoria** indexada por el tiempo. Lo que tenemos es **una** realización $\{y_t\}$ de infinitas posibles.

- ▶ El **orden importa**: y_t depende de su pasado.
- ▶ Esa **dependencia** (autocorrelación) es lo que permite pronosticar.

Idea clave

Pronosticar es **modelar la estructura de dependencia** del proceso, no promediar puntos que se supongan independientes.



Por qué la regresión lineal *no* es para pronosticar series




Regresión (OLS): $y = X\beta + \varepsilon$


Supone ε **i.i.d.** La autocorrelación es una *violación* que se “corrige” (GLS, errores robustos) solo para poder **inferir** β .

Pronóstico: $y_t = f(\text{pasado de } y, \text{ shocks})$


La dependencia temporal **es la señal** que se modela (AR, MA, estado).



- Tendencia **determinista** (recta) $\neq$ **estocástica** (raíz unitaria): los shocks son *permanentes*, la serie no vuelve a la recta.
- Los intervalos de OLS **no crecen** con el horizonte $\Rightarrow$ sobreconfianza.



Durbin–Watson puede *engañarte*



Cuidado

DW solo mide autocorrelación de **rezago 1**. Una serie puede dar $DW \approx 2$ (“errores independientes”) y **no** ser ruido blanco: queda dependencia estacional o de orden superior sin modelar.


Idea clave

El diagnóstico correcto es **ruido blanco** (ACF completa + Ljung–Box), no un único rezago.


Dos trampas, con números

(A) Ajusto $y \sim t$ a una serie con dependencia estacional: $R^2 \approx 0,00$, pero $DW = 2,19$ y $\rho_1 = -0,10$ ($\Rightarrow$ “independiente”) mientras $\rho_{12} = 0,81$ y Ljung–Box(24) da $p \approx 3 \times 10^{-82}$. (B) Regresión espuria (y, x dos random walks independientes): $R^2 = 0,25$, pendiente “significativa” $t = 6,2$ ($p \approx 7 \times 10^{-9}$), pero $DW = 0,12$.


Las tres componentes, una a una



tiempo

Tendencia: nivel que cambia lento

tiempo


Estacionalidad: período fijo m 

tiempo

Ruido: variación irregular

Idea clave

Cada componente sugiere una familia de modelos: tendencia → Holt; estacionalidad → Holt-Winters/SARIMA; ruido → lo que el modelo debe *dejar*, no explicar.



Ciclo frente a estacionalidad



Estacionalidad


Período **fijo** y conocido (12 meses). Predecible.

Ciclo


Período **variable** (económico). Difícil de anticipar.

Cuidado

Confundir un **ciclo** con estacionalidad lleva a modelar un patrón periódico que en realidad no se repite con regularidad.



Descomposición: las tres componentes juntas



Idea clave


La serie observada (naranja) = tendencia (azul) + estacionalidad (verde) + ruido.




Estacionalidad aditiva o multiplicativa



aditiva: amplitud constante




multiplicativa: crece con el nivel



Idea clave

Si la amplitud de los picos **crece con el nivel**, la estacionalidad es **multiplicativa** (típico en demanda). Esto decide la variante de ETS/Holt-Winters.




Los datos reales traen patologías




Patología	Efecto si se ignora
Datos faltantes	rompe la estacionalidad
Valores atípicos	sesga el nivel y la tendencia
Quiebres estructurales	el modelo promedia dos regímenes
Demanda promocional	se confunde con estacionalidad
Demanda intermitente	el promedio no describe nada
Ventas censuradas	subestima la demanda

Implicancia operacional

Diagnosticar estas patologías es parte del trabajo, no un paso opcional.



Faltantes y atípicos: dos patologías que hay que ver



Datos faltantes (hueco)

Feriados, fallas de registro. **Marcar**, no rellenar a ciegas; imputar *dentro* de cada serie y *después* de particionar.

Valores atípicos (pico)


Error de carga, evento o promoción. Distinguir la **causa** antes de tratar; no eliminar en automático.

Cuidado

Interpolarse sobre **toda** la serie (faltantes) o borrar un pico que era demanda real (atípico) introduce *leakage* o sesgo.



Cambios estructurales (quiebres de régimen)




Un cambio de nivel permanente

Nuevo canal, cambio de planta, pandemia. El pasado lejano **ya no aplica**.

Implicancia operacional

Tratamiento: ventana deslizante, variable indicadora o modelo de cambio de régimen.



Demanda promocional



Picos *inducidos*


No son estacionalidad: dependen de una **decisión comercial**, no del calendario.

Cuidado


Si se modela como estacionalidad, el pronóstico “inventará” picos donde no habrá promoción.

Implicancia operacional

Mejor: incluir la promoción como **regresor externo** (Unidad 2).



Demanda intermitente




Muchos ceros, picos aislados

Típica en repuestos y baja rotación. El promedio no representa ningún valor observable.

Idea clave

Requiere métodos especializados (Croston/SBA/TSB, Unidad 6) y métricas distintas.



Distinción crítica: ventas $\neq$ demanda




Definiciones


- ▶ **Demanda:** lo que el cliente quiso comprar (no siempre observable).
- ▶ **Ventas:** lo que se vendió, **limitado por el stock disponible**.

Idea clave

Con quiebre de stock: ventas $\leq$ demanda. Las ventas están **censuradas**.




Ventas censuradas: la ilustración



Implicancia operacional

Durante el quiebre (zona roja) las ventas caen a lo disponible, aunque la **demanda** seguía alta. Modelar ventas como demanda **subestima** sistemáticamente y perpetúa el faltante.



Fuga de información (*leakage*) temporal




Usar información que no se tendrá al decidir

Cualquier cálculo que emplee datos **posteriores** al instante de la decisión.

Cuidado

El *leakage* infla el desempeño en evaluación y **colapsa** en producción. Es el error más común y más caro del pronóstico.




Tres formas clásicas de *leakage*



1. Escalar o imputar con estadísticos calculados sobre **toda** la serie.
2. Usar variables que solo se conocen **después** del instante de decisión.
3. Elegir modelo o hiperparámetros **mirando el conjunto de prueba**.

Idea clave

Regla de oro: todo cálculo que dependa de los datos se ajusta **solo** con el tramo de entrenamiento.



Partición temporal: entrenamiento y prueba




Fold 1


entrenar (pasado)

evaluar (futuro)


- ▶ El orden **importa**: siempre pasado → futuro.
- ▶ **Nunca** validación cruzada aleatoria en series.
- ▶ La prueba permanece **intacta** hasta congelar el modelo.




Partición temporal: entrenamiento y prueba




- ▶ El orden **importa**: siempre pasado → futuro.
- ▶ **Nunca** validación cruzada aleatoria en series.
- ▶ La prueba permanece **intacta** hasta congelar el modelo.



Partición temporal: entrenamiento y prueba



- ▶ El orden **importa**: siempre pasado → futuro.
- ▶ **Nunca** validación cruzada aleatoria en series.
- ▶ La prueba permanece **intacta** hasta congelar el modelo.




Python: cargar, inspeccionar y particionar en el tiempo



```
import pandas as pd
# serie mensual indexada por fecha (sin barajar!)
y = pd.read_csv('ventas.csv', parse_dates=['fecha'],
               index_col='fecha')['demanda']
y = y.asfreq('MS') # frecuencia mensual explicita
corte = '2024-12-31'
train = y.loc[:corte] # pasado -> ajuste
test = y.loc[pd.Timestamp(corte) + pd.offsets.MonthBegin():] # futuro
print(train.shape, test.shape, y.isna().mean()) # cobertura de faltantes
```

Implicancia operacional


Fijar asfreq evita huecos silenciosos que rompen la estacionalidad.



Errores frecuentes en el diagnóstico



- ▶ Confundir **ventas con demanda** ante quiebres de stock.
- ▶ Barajar los datos o usar *k-fold* aleatorio “porque funciona en ML”.
- ▶ Imputar o escalar con estadísticos de **toda** la serie.
- ▶ Elegir la frecuencia por comodidad y no por la decisión.
- ▶ Tratar un **pico promocional** como estacionalidad.





Qué debe quedar claro


- ▶ Pronóstico $\neq$ meta $\neq$ plan.
- ▶ Ventas $\neq$ demanda ante quiebres.
- ▶ La partición temporal es la base de todo.

Checklist de interpretación

- ▶ ¿Qué horizonte pide la decisión?
- ▶ ¿Hay *leakage* escondido?
- ▶ ¿Qué componentes veo?

Actividad:

Para preparar la siguiente clase Traer una serie propia (o del dataset del curso) y proponer: frecuencia, horizonte, nivel y corte train/test.



¿Por qué empezar por métodos simples?




Los benchmarks no son opcionales

- ▶ Un modelo complejo solo se justifica si **supera** a uno simple.
- ▶ Los métodos ingenuos son **rápidos, robustos e interpretables**.
- ▶ En muchas series operacionales son **difíciles de batir**.

Idea clave

“Mi RMSE es 12” no dice nada sin un punto de comparación.




Los tres métodos ingenuos (benchmarks)



Método	Fórmula	Cuándo
Naive	$\hat{y}_{t+h} = y_t$	sin tendencia ni estacionalidad
Naive estacional	$\hat{y}_{t+h} = y_{t+h-m}$	estacionalidad marcada
Deriva (<i>drift</i>)	$\hat{y}_{t+h} = y_t + h \frac{y_t - y_1}{t - 1}$	tendencia aprox. lineal

Idea clave

Batir al benchmark apropiado es el **mínimo exigible** a cualquier modelo: define el punto de comparación.



Ejemplo numérico: naive vs SES vs deriva



Demanda mensual (unidades)

	entrenamiento						prueba	
Mes t	1	2	3	4	5	6	7	8
Demanda y_t	20	22	21	24	23	26	25	28

- **Naive:** $\hat{y} = y_6 = 26$ (último valor) $\Rightarrow$ meses 7–8: (26, 26).
- **Deriva:** pendiente $\frac{y_6 - y_1}{5} = \frac{26 - 20}{5} = 1,2 \Rightarrow (27,2, 28,4)$.
- **SES** ($\alpha = 0,5$): niveles $20 \rightarrow 21 \rightarrow 21 \rightarrow 22,5 \rightarrow 22,75 \rightarrow \mathbf{24,375} \Rightarrow (24,4, 24,4)$.

Idea clave

Se ajusta con los meses 1–6 y se pronostican los meses 7–8. La deriva captura la tendencia; SES la rezaga.



¿Cuál gana? Comparación por error




Método	Pronóstico	Errores ($y - \hat{y}$)	MAE
Naive	(26, 26)	(-1, +2)	1,50
SES ($\alpha=0,5$)	(24,4, 24,4)	(+0,6, +3,6)	2,12
Deriva	(27,2, 28,4)	(-2,2, -0,4)	1,30

Implicancia operacional

En una serie con **tendencia**, la deriva vence a SES y al naive. Lección: el método debe ajustarse a la **estructura** de la serie.

↪ *Replícalo:* `StatsForecast([Naive(), SES(0.5), RWD()], freq='MS')` y compara el MAE.



Medias móviles y el compromiso de suavizado




$$\hat{y}_{t+1} = \frac{1}{k} \sum_{i=0}^{k-1} y_{t-i}$$

- ▶ **k pequeño**: reacciona, pero sigue el ruido.
- ▶ **k grande**: más suave, pero **rezaga**.

Promedia las últimas k observaciones para **suavizar el ruido**.

Idea clave

Suavizar siempre cuesta **rezago**. La versión **ponderada** ($\sum w_i y_{t-i}$, con pesos decrecientes) es el puente hacia el suavizamiento exponencial.



Suavizamiento exponencial simple (SES)




$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t, \quad 0 < \alpha < 1$$



- ▶ Una **recursión**: el pronóstico nuevo corrige el anterior con el último error.
- ▶ Un **solo parámetro** α resume cuánto pesa lo reciente.

Idea clave

SES = “memoria con olvido”.




SES: los pesos decaen geométricamente



Idea clave

α bajo (izq.): memoria **larga**, muchos datos pesan. α alto (der.): memoria **corta**, casi solo el último dato.




SES: efecto de α sobre la reactividad

Implicancia operacional

Ante un cambio de nivel: α alto **engancha rápido** (más ruido); α bajo **rezaga** (más suave). No existe un α “bueno” universal: depende de la serie.



SES: cómo se ajusta el nivel, paso a paso




Idea clave

La recursión actualiza el nivel **una vez por período**: absorbe el salto de forma gradual y converge al nuevo régimen.



SES: cómo se ajusta el nivel, paso a paso

 $t = 1 \dots 4$: nivel estable

Idea clave


La recursión actualiza el nivel **una vez por período**: absorbe el salto de forma gradual y converge al nuevo régimen.



SES: cómo se ajusta el nivel, paso a paso



$t = 5$: llega el salto, el nivel sube



Idea clave


La recursión actualiza el nivel **una vez por período**: absorbe el salto de forma gradual y converge al nuevo régimen.



SES: cómo se ajusta el nivel, paso a paso



el nivel converge al nuevo régimen



Idea clave

La recursión actualiza el nivel **una vez por período**: absorbe el salto de forma gradual y converge al nuevo régimen.



SES: para qué series




Apropiado

Series **sin** tendencia ni estacionalidad, con nivel que deriva lentamente.

Cuidado

Con tendencia, SES **rezaga** sistemáticamente: hay que añadir una ecuación de tendencia (Holt).



Método de Holt: añadir tendencia



Dos ecuaciones que se actualizan juntas

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$


(nivel)

$$b_t = \beta (\ell_t - \ell_{t-1}) + (1 - \beta) b_{t-1}$$


(pendiente)

Implicancia operacional

Ahora el pronóstico extrapola una **pendiente**, no un nivel plano.



Holt-Winters: añadir estacionalidad



Idea clave


Nivel + tendencia + componente estacional $\Rightarrow$ el pronóstico reproduce la forma completa de la serie.




Holt-Winters: aditiva o multiplicativa



aditiva: amplitud constante




multiplicativa: crece con el nivel



Idea clave

Amplitud constante $\Rightarrow$ **aditiva**. Amplitud que crece con el nivel $\Rightarrow$ **multiplicativa** (típica en demanda).




La familia ETS (Error–Trend–Seasonal)



Un marco unificado

Cada componente puede ser **Ninguno**, **Aditivo** o **Multiplicativo**.

Notación	Equivale a
ETS(A,N,N)	SES
ETS(A,A,N)	Holt
ETS(A,A,A)	Holt-Winters aditivo
ETS(M,A,M)	Holt-Winters multiplicativo




ETS: selección automática y ventajas



- ▶ Elige la combinación E/T/S **automáticamente** por verosimilitud/AICc.
- ▶ Produce **intervalos** de predicción (formulación en espacio de estados → Unidad 3).
- ▶ Robusto, rápido y muy usado en la práctica operacional.

Idea clave

ETS unifica todo lo anterior en un solo procedimiento.



Python: preparar los datos (formato largo)




statsforecast espera tres columnas: unique_id (la serie), ds (fecha) y y (valor). Este es el paso que más se olvida.

```
df = (ventas.groupby(['familia', 'fecha'])['ventas'].sum() # a nivel familia
      .reset_index()
      .rename(columns={'familia': 'unique_id', 'fecha': 'ds', 'ventas': 'y'}))
df_train = df[df['ds'] <= corte] # particion temporal
df_train.head() # unique_id / ds / y
```

Idea clave

Cada serie es un unique_id: así una sola llamada ajusta **todas** las familias a la vez.




Python: ETS automático con statsforecast



```
from statsforecast import StatsForecast
from statsforecast.models import AutoETS, SeasonalNaive
sf = StatsForecast(
    models=[SeasonalNaive(season_length=12), # benchmark obligatorio
            AutoETS(season_length=12)], # ETS elegido por AICc
    freq='MS')
sf.fit(df_train)
fc = sf.predict(h=6, level=[80, 95]) # punto + intervalos 80/95%
```

Implicancia operacional

Reportar ETS *contra* el naive estacional: si no lo supera, se usa el simple.



De los parámetros a la ecuación: SES



Ajuste

SimpleExpSmoothing estima un solo parámetro:

$$\hat{\alpha} = 0,53$$


Ecuación de actualización

$$\ell_t = 0,53 y_t + 0,47 \ell_{t-1}$$

$$\hat{y}_{t+h|t} = \ell_t \quad (\text{plano})$$

Implicancia operacional

$\alpha = 0,53$: el nivel pondera casi mitad y mitad el dato nuevo y la historia. $\alpha \rightarrow 1$ = reactivo (naive); $\alpha \rightarrow 0$ = inercial (media).



De los parámetros a la ecuación: Holt



Ajuste

$$\hat{\alpha} = 0,38 \quad \hat{\beta} = 0,38$$

(nivel y pendiente)

Dos ecuaciones + pronóstico


$$\ell_t = 0,38 y_t + 0,62 (\ell_{t-1} + b_{t-1})$$

$$b_t = 0,38 (\ell_t - \ell_{t-1}) + 0,62 b_{t-1}$$

$$\hat{y}_{t+h|t} = \ell_t + h b_t$$

Implicancia operacional

β controla cuánto se **actualiza la pendiente**. El pronóstico ya **no** es plano: crece $h b_t$ por paso.



De los parámetros a la ecuación: Holt-Winters

Ajuste (aditivo, $m=12$)

$$\hat{\alpha} = 0,25$$

$$\hat{\beta} \approx 0$$

$$\hat{\gamma} = 0,45$$

Tres ecuaciones + pronóstico

$$\ell_t = 0,25 (y_t - s_{t-m}) + 0,75 (\ell_{t-1} + b_{t-1})$$


$$b_t = 0 \cdot (\ell_t - \ell_{t-1}) + 1 \cdot b_{t-1}$$

$$s_t = 0,45 (y_t - \ell_t) + 0,55 s_{t-m}$$

$$\hat{y}_{t+h|t} = \ell_t + h b_t + s_{t+h-m}$$

Implicancia operacional

$\hat{\beta} \approx 0$: la **pendiente es estable** (no se reestima). $\hat{\gamma} = 0,45$: la **estacionalidad sí** evoluciona. Los parámetros *cuentan* la dinámica de la serie.



Introducción aplicada a SARIMA




SARIMA(p, d, q)(P, D, Q) $_m$ desde el uso


- ▶ Modela la **dependencia** entre observaciones (autocorrelación).
- ▶ d, D : diferenciación regular y estacional (quita tendencia/estacionalidad).
- ▶ p, q, P, Q : memoria autorregresiva y de medias móviles.

Cuidado

En esta unidad SARIMA se **usa e interpreta**, sin derivación. La teoría completa es la Unidad 2 del magister.




¿Qué “ve” SARIMA que ETS no?



Autocorrelación

SARIMA modela **explícitamente** la correlación entre una observación y sus rezagos; ETS la trata como componentes.




Python: SARIMA automático y comparación



```
from statsforecast.models import AutoARIMA
sf = StatsForecast(models=[AutoARIMA(season_length=12)], freq='MS')
sf.fit(df_train) # busca (p,d,q) (P,D,Q) por AICc
fc = sf.predict(h=6, level=[95])
# comparar contra ETS y SeasonalNaive con la MISMA particion temporal
```

Idea clave

Automatizar la búsqueda no exime de **validar**: el AICc mide ajuste dentro de muestra, no desempeño futuro.




¿Cuál método elegir? Guía rápida



Situación	Primera opción	Benchmark
Sin tendencia ni estacionalidad	SES / ETS(A,N,N)	Naive
Tendencia, sin estacionalidad	Holt / drift	Drift
Tendencia + estacionalidad	AutoETS / Holt-Winters	Naive estacional
Autocorrelación marcada	AutoARIMA	AutoETS
Muchos ceros (intermitente)	Croston (Unidad 6)	Naive

Implicancia operacional

La elección **final** la decide la validación temporal (Semana 3), no la tabla.




¿Qué captura cada método?



Método	Nivel	Tendencia	Estacional	Autocorr.
Naive / MA	✓			
SES	✓			
Holt	✓	✓		
Holt-Winters / ETS	✓	✓	✓	
SARIMA	✓	✓	✓	✓

Idea clave

Cada método añade una capacidad. Elegir el más simple que capture la estructura **presente** en la serie: ni menos (subajuste) ni más (sobreajuste).



Ejemplo: el efecto de α en números



Ejemplo numérico


Misma serie con escalón $3 \rightarrow 7$ en $t = 5$. Nivel SES tras el salto:

	$t = 5$	$t = 6$	$t = 7$	$t = 8$
$\alpha = 0,7$	6,2	6,8	6,9	7,0
$\alpha = 0,2$	3,8	4,4	5,0	5,4

Implicancia operacional

$\alpha = 0,7$ alcanza el nuevo nivel en 3 períodos; $\alpha = 0,2$ sigue lejos en el período 8. **Reactividad vs suavidad** es la elección de α .


↪ *Replícalo*: Itera $lv1 = a*y + (1-a)*lv1$ para cada α y compara.



Errores frecuentes con métodos clásicos



- ▶ No incluir un **benchmark** ingenuo.
- ▶ Usar estacionalidad **aditiva** cuando la amplitud crece con el nivel.
- ▶ Ajustar α o el orden **mirando el test**.
- ▶ Reportar solo el punto, sin **intervalos**.
- ▶ Confiar en AutoARIMA/AutoETS **sin validar** fuera de muestra.



Qué debe quedar claro

- ▶ Naive/estacional son benchmarks obligatorios.
- ▶ SES suaviza con “memoria y olvido”; α regula la reactividad.
- ▶ ETS unifica nivel, tendencia y estacionalidad.

Checklist de interpretación

- ▶ ¿Superé al benchmark?
- ▶ ¿Aditiva o multiplicativa?
- ▶ ¿Validé fuera de muestra?

Actividad:

Para preparar la siguiente clase Ajustar SeasonalNaive, AutoETS y AutoARIMA a una familia y comparar sus pronósticos a 6 pasos.



¿Qué significa que un pronóstico sea “bueno”?




No hay una única respuesta

- ▶ Depende del **horizonte**, del **costo del error** y del **uso**.
- ▶ Un modelo puede ganar a 1 paso y perder a 6.
- ▶ Precisión *promedio* $\neq$ utilidad operacional.

Idea clave

El mejor modelo es el **apropiado al contexto**, no el de menor error medio.




Métricas de error puntual



A partir del error $e_t = y_t - \hat{y}_t$, cada métrica lo resume de una forma distinta y responde una pregunta operacional distinta:

Métrica	Fórmula	Lectura
MAE	$\frac{1}{n} \sum e_t $	error medio, misma unidad
RMSE	$\sqrt{\frac{1}{n} \sum e_t^2}$	penaliza errores grandes
MAPE	$\frac{100}{n} \sum e_t/y_t $	%; explota si $y_t \rightarrow 0$
WAPE	$100 \frac{\sum e_t }{\sum y_t }$	% ponderado por volumen
Bias	$\frac{1}{n} \sum e_t$	sesgo (sobre/subestima)



Ejemplo numérico: calcular las métricas



Ejemplo numérico

Real $y = (25, 28, 30)$, pronóstico $\hat{y} = (26, 26, 33) \Rightarrow e = (-1, +2, -3)$.

$$\text{MAE} = \frac{1+2+3}{3} = 2,00 \quad \text{RMSE} = \sqrt{\frac{1+4+9}{3}} = 2,16$$

$$\text{Bias} = \frac{-1+2-3}{3} = -0,67 \quad \text{MAPE} = 7,05 \% \quad \text{WAPE} = 100 \frac{6}{83} = 7,23 \%$$

Implicancia operacional

$\text{RMSE} > \text{MAE}$ porque un error grande (-3) pesa más. El Bias negativo avisa que el modelo **subestima**.

↪ *Replicalo:* $e = y - \text{yhat}$; luego $\text{np.mean}(\text{np.abs}(e))$, $\text{np.sqrt}(\text{np.mean}(e**2))$...



MAE frente a RMSE



MAE


Trata todos los errores **por igual**. Robusto a valores extremos.

RMSE

Penaliza **cuadráticamente**: un error grande domina.

Implicancia operacional

Use RMSE si los errores grandes son muy costosos; MAE/WAPE para robustez e interpretación.



El Bias: la métrica que casi todos olvidan




Sesgo sistemático

Bias > 0 : sobreestima. Bias < 0 : subestima. Un modelo puede tener buen RMSE y mal Bias.

Cuidado

Un sesgo persistente **descalibra el inventario**: acumula exceso o faltante trimestre tras trimestre.



El problema del MAPE




Cuidado

El MAPE divide por y_t : **explota** cuando la demanda se acerca a cero y penaliza **asimétricamente** (castiga más sobreestimar).

Implicancia operacional

En catálogos con baja rotación prefiera **WAPE** (pondera por volumen y tolera ceros).




El zoológico de métricas: cuál usar



Objetivo	Métrica	Nota
Interpretable, robusta	MAE, WAPE	unidades / %
Penalizar errores grandes	RMSE, RMSSE	cuadrática
Comparar entre series	MASE, RMSSE	escaladas
Detectar sesgo	Bias	signo importa
Evaluar cuantiles	pinball, CRPS	Unidad 6

Idea clave

No existe “la” métrica: se elige según el **uso** y el **costo**. Reportar siempre *al menos* una escalada (MASE) y el Bias.



Comparar contra un benchmark: MASE

$$\text{MASE} = \frac{\text{MAE del modelo}}{\text{MAE del naive en entrenamiento}}$$

Ejemplo numérico

Con el ejemplo anterior ($\text{MAE} = 2,0$) y una serie de entrenamiento 20, 22, 21, 24, 23, 26: el naive tiene $\text{MAE}_{\text{train}} = \frac{|22-20|+\dots}{5} = 2,0$.

$$\text{MASE} = \frac{2,0}{2,0} = \mathbf{1,00} \Rightarrow \text{el modelo } \textit{igual} \text{ al naive: no aporta.}$$

Idea clave

$\text{MASE} < 1$: mejor que el naive; > 1 : peor. Adimensional $\Rightarrow$ comparable entre series y escalas (análogo cuadrático: RMSSE).



Por qué NO validación cruzada aleatoria




Cuidado

Barajar mezcla futuro y pasado: el modelo “ve” información que en producción no tendría. El resultado es optimista y **falso**.

En su lugar

- ▶ Holdout **temporal**.
- ▶ **Rolling origin** (origen deslizante).
- ▶ Ventana **expansiva** o **deslizante**.




Holdout temporal




Idea clave

Un solo corte da **una** estimación del error. Para una estimación estable se usan varios orígenes.




Rolling origin: el origen avanza




entrenar (pasado)

evaluar (futuro)


- ▶ Se reentrena avanzando el origen y se evalúa el bloque siguiente.
- ▶ Da una **distribución** de errores, no un solo número.




Rolling origin: el origen avanza




- ▶ Se reentrena avanzando el origen y se evalúa el bloque siguiente.
- ▶ Da una **distribución** de errores, no un solo número.



Rolling origin: el origen avanza



- ▶ Se reentrena avanzando el origen y se evalúa el bloque siguiente.
- ▶ Da una **distribución** de errores, no un solo número.



Validación cruzada temporal, paso a paso




La receta

1. Fijar horizonte h (p. ej. 6) y número de pliegues (*windows*).
2. **Pliegue 1:** entrenar con $1..t_0$, pronosticar $t_0+1..t_0+h$, medir el error.
3. **Pliegue 2:** avanzar el origen (t_0+1), reentrenar, pronosticar, medir.
4. Repetir; el error CV es el **promedio** sobre todos los pliegues.

Cuidado

En cada pliegue, cualquier ajuste (escalado, imputación, selección de λ) se hace **solo** con el tramo de entrenamiento de ese pliegue. Tocar el bloque de prueba es *leakage*.



Ventana expansiva frente a deslizante



Expansiva


La ventana de entrenamiento **crece**: usa toda la historia.

Deslizante


Tamaño **fijo**: útil si hay quiebres y el pasado lejano ya no aplica.

Implicancia operacional

Con cambio de régimen reciente, la ventana deslizante suele ser preferible.



Comparar modelos sobre la misma serie




Qué se ve


- ▶ **SES**: pronóstico *plano*, ignora tendencia y estación.
- ▶ **Holt**: extrapola tendencia pero **no** estacionalidad → se aleja.
- ▶ **SARIMA**: sigue el patrón estacional.

Idea clave

El modelo debe **coincidir con la estructura** de la serie: usar Holt en datos estacionales es un error de diseño, no de ajuste.



El veredicto de la validación cruzada



Serie mensual, 6 pliegues, $h=6$

WAPE CV (media $\pm$ sd):

SES $10,0 \pm 2,1$; Holt $16,3 \pm 8,9$;

Holt-Winters $3,5 \pm 0,6$; SARIMA

$3,5 \pm 0,6$.


Implicancia operacional

Holt no solo es peor: es **inestable** (sd 8,9). Holt-Winters y SARIMA empatan como mejores y **consistentes**.

↪ *Replicalo:* `cross_validation(h=6, n_windows=6)`; WAPE por pliegue, luego media y sd.



Error por horizonte de cada modelo




La estabilidad importa

El error de **Holt** crece sin control con el horizonte (la tendencia mal puesta se amplifica); **SARIMA** se mantiene bajo y plano.

Idea clave

Un promedio esconde esto: solo el error **por horizonte** muestra dónde un modelo deja de servir.



Cómo se elige el mejor modelo




No siempre el de menor error puntual


1. Filtrar por **estructura**: descartar los que ignoran componentes presentes (Holt aquí).
2. Comparar por **CV** (media y variabilidad) al horizonte de decisión.
3. Ante **empate** (± 1 sd): regla **1-SE** $\rightarrow$ el más **simple/interpretable**.
4. Desempatar con **Bias**, costo asimétrico y estabilidad entre pliegues.

Idea clave

Holt-Winters y SARIMA empatan; por parsimonia e interpretación se puede preferir Holt-Winters, salvo que se necesiten regresores (SARIMAX).




El error crece con el horizonte



Evaluar por horizonte

El desempeño a $h = 1$ no predice el desempeño a $h = 6$. Reportar el error **a cada horizonte** revela dónde el modelo deja de servir.



Ejemplo: comparación real por horizonte



Comparación – familia Bebidas/Gaseosas, rolling origin

WAPE (%)	$h=1$	$h=3$	$h=6$	promedio
SeasonalNaive	20,4	21,0	17,8	19,3
AutoETS	14,1	17,8	22,9	18,3
SARIMA	16,7	12,6	23,0	21,0

Implicancia operacional

A $h=1$ gana AutoETS; a $h=6$ gana el **SeasonalNaive**. La respuesta **cambia con el horizonte**: por eso se evalúa a cada h , no en promedio.

↪ *Replícalo:* `sf.cross_validation(df, h=6, n_windows=8)` sobre el dataset del curso.




Python: validación temporal con statsforecast



```
from statsforecast.models import AutoETS, SeasonalNaive, AutoARIMA
sf = StatsForecast(
    models=[SeasonalNaive(season_length=12), AutoETS(12), AutoARIMA(12)],
    freq='MS')
cv = sf.cross_validation(df=df, h=6, step_size=1, n_windows=8) # rolling origin
# cv trae: ds, cutoff, y, y una columna por modelo -> error por horizonte
```

Implicancia operacional

`n_windows` y `step_size` fijan cuántos orígenes; a más ventanas, estimación más estable del error.




Python: WAPE por horizonte, sin *leakage*




```
import numpy as np
def wape(y, yhat): return 100*np.sum(np.abs(y-yhat))/np.sum(np.abs(y))
dh = cv['ds'].dt.to_period('M') - cv['cutoff'].dt.to_period('M')
cv['h'] = dh.apply(lambda x: x.n) # horizonte de cada fila
tabla = cv.groupby('h').apply(
    lambda g: wape(g['y'], g['AutoETS'])) # WAPE por horizonte
print(tabla) # el error casi siempre CRECE con h
```

Idea clave

Evaluar **por horizonte** es la lectura correcta de una validación temporal.




Intervalos de predicción: primera mirada



- El punto es insuficiente para decidir stock.
- Un intervalo del 95 % **debe** cubrir $\approx 95\%$ de los reales.
- **Cobertura y amplitud** se validan (Unidad 6).

Implicancia operacional

Un intervalo demasiado angosto “se ve preciso” pero genera quiebres.



Ejemplo numérico: cobertura de un intervalo



Ejemplo numérico


Un modelo entrega intervalos del 90 %. Sobre 10 semanas de prueba, la demanda real cae **dentro** del intervalo en 7 de ellas.

$$\text{Cobertura empírica} = \frac{7}{10} = 70 \% \ll 90 \% \text{ nominal.}$$

Cuidado

Cobertura muy por debajo de lo nominal $\Rightarrow$ el modelo **subestima** la incertidumbre. El stock de seguridad calculado con ese intervalo será insuficiente.

$\hookrightarrow$ *Replicalo:* `np.mean((y>=lo) & (y<=hi))` sobre el conjunto de prueba.



Checklist de una validación correcta



Sí


- ▶ Partición **temporal** (pasado→futuro).
- ▶ **Rolling origin**, varias ventanas.
- ▶ Error **por horizonte**.
- ▶ Al menos MASE + Bias.
- ▶ Benchmark incluido.

No


- ▶ *k*-fold aleatorio.
- ▶ Un solo corte, una sola métrica.
- ▶ Imputar/escalar con todo.
- ▶ Elegir mirando el test.
- ▶ MAPE con ceros.

Idea clave

Esta lista **es** el criterio de corrección de los casos del curso.



El costo del error es asimétrico




Sub vs sobre

Subestimar: quiebre, venta perdida.

Sobrestimar: exceso, obsolescencia.

Cuidado

Elegir el modelo de menor RMSE puede ser **subóptimo** si quebrar cuesta mucho más que sobre-stockear. La métrica debe reflejar el costo.



El mejor modelo no es el de menor error promedio




Depende de

- ▶ el **horizonte** de la decisión;
- ▶ el **costo asimétrico** de los errores;
- ▶ la **estabilidad** entre orígenes;
- ▶ el **Bias**, no solo la magnitud.

Idea clave


Una sola métrica y un solo origen **nunca** bastan.



Errores frecuentes en evaluación



- ▶ Elegir modelo por ajuste **dentro** de muestra (AIC) sin validar fuera.
- ▶ Una **sola** métrica y un **solo** origen.
- ▶ Ignorar el **Bias** y el desempeño por horizonte.
- ▶ MAPE con series que tocan cero.
- ▶ Optimizar hiperparámetros contra el **test**.





Qué debe quedar claro


- ▶ Validación temporal, nunca aleatoria.
- ▶ Rolling origin + error por horizonte.
- ▶ MASE compara contra lo trivial.

Checklist de interpretación


- ▶ ¿Superé al benchmark ($MASE < 1$)?
- ▶ ¿Revisé el Bias?
- ▶ ¿La métrica refleja el costo?

Actividad:

Para preparar la siguiente clase Correr cross_validation sobre una familia, tabular WAPE y MASE por horizonte y recomendar un modelo.



La demanda vive en una jerarquía




Niveles típicos

Empresa → categoría → familia → subfamilia
→ SKU.

Idea clave

El nivel de pronóstico es una **elección**, no un dato.




Las decisiones ocurren en distintos niveles




Nivel	Decisión que apoya
Empresa / categoría	S&OP, presupuesto, capacidad
Familia	compras, planificación agregada
SKU	reposición, punto de reorden

Implicancia operacional

Cada nivel de la jerarquía de productos **es** un nivel de decisión de operaciones.




Estabilidad frente a granularidad



- ▶ Arriba: más **señal**, se pronostica mejor en %.
- ▶ Abajo: el SKU es **ruidoso** e intermitente. . .
- ▶ . . . pero la reposición necesita el **SKU**.

Idea clave

Pronosticar donde hay señal y **repartir** hacia donde se decide: ese es el problema jerárquico.



Jerarquías: no solo de productos



Anidadas (un solo padre)


- ▶ Productos: categoría→familia→SKU.
- ▶ Geográficas: país→región→CD.
- ▶ Organizacionales: división→sucursal.

Cruzadas / agrupadas

Atributos que se **cruzan**: producto $\times$ canal $\times$ región. Un nodo tiene **varios** padres.

Implicancia operacional

La estructura la define la **decisión**: se pronostica en los niveles donde se decide (reposición, S&OP, compras).




Tres enfoques de coherencia



Estrategias clásicas

- ▶ **Bottom-up:** pronosticar SKU y **sumar** hacia arriba.
- ▶ **Top-down:** pronosticar el total y **repartir** por proporciones.
- ▶ **Middle-out:** pronosticar en un nivel intermedio; sumar hacia arriba y repartir hacia abajo.




Sumar los SKU

$$\hat{y}_{\text{familia}} = \sum_{i \in \text{familia}} \hat{y}_i$$

- + Conserva el detalle del SKU.
- **Acumula** el ruido de cada SKU.

Implicancia operacional

Peligroso con muchos SKU intermitentes: la suma hereda toda su varianza.






Repartir el total

$$\hat{y}_i = p_i \cdot \hat{y}_{\text{total}}, \quad \sum_i p_i = 1$$

- + Estable en el nivel superior.
- Proporciones erróneas abajo si cambia el *mix*.




Top-down: ¿cómo se calculan las proporciones?



- ▶ Por **proporciones históricas** promedio: $p_i = \overline{(y_i / y_{\text{total}})}$.
- ▶ Por **proporción de promedios**: $p_i = \overline{y_i} / \overline{y_{\text{total}}}$.
- ▶ Por proporciones **pronosticadas** (más sofisticado).

Cuidado

Las proporciones fijas fallan cuando cambia el **mix** (nuevos SKU, canibalización, promociones): la coherencia se mantiene, pero la exactitud del SKU cae.



Ejemplo numérico: bottom-up vs top-down



Ejemplo numérico


Una familia con 2 SKU. Historia media: $SKU_1 \approx 41,5$, $SKU_2 \approx 19,5 \Rightarrow$ proporciones $p_1 = 0,68$, $p_2 = 0,32$.

- ▶ **Bottom-up:** pronóstico $SKU_1 = 44$, $SKU_2 = 22 \Rightarrow$ total = $44 + 22 = 66$.
- ▶ **Top-down:** pronóstico total = 66; reparto $\Rightarrow$ $SKU_1 = 66 \cdot 0,68 = 44,9$, $SKU_2 = 66 \cdot 0,32 = 21,1$.

Implicancia operacional

Ambos son **coherentes** (suman 66), pero asignan distinto al SKU. ¿Cuál es mejor? Lo decide la **validación por nivel**, no la aritmética.

↪ *Replícalo:* Construye la tabla SKU $\times$ fecha, suma y reparte por proporciones.



Middle-out




Lo mejor de ambos

Pronosticar en un nivel **intermedio** estable (familia), sumar hacia arriba y repartir hacia abajo.

Idea clave

Útil cuando la **familia** tiene señal suficiente y las decisiones bajan al SKU.




Comparación de los tres enfoques



Enfoque	Ventaja	Riesgo
Bottom-up	conserva detalle	acumula ruido del SKU
Top-down	estable arriba	proporciones erróneas abajo
Middle-out	equilibrio	elegir bien el nivel medio

Implicancia operacional

En Unidad 5 veremos la reconciliación óptima (MinT), que generaliza los tres.




Definición operacional

Un conjunto de pronósticos es **coherente** si los de los hijos **suman** exactamente el del padre en toda la jerarquía.

- ▶ Pronosticar cada nivel por separado casi nunca es coherente.
- ▶ La incoherencia genera **planes contradictorios** entre S&OP y reposición.

Idea clave

La coherencia es un requisito de **gobernanza**: un solo número por nivel.



Ejemplo: la incoherencia genera dos planes



Ejemplo numérico

Comercial pronostica la familia en **100**. Reposición pronostica sus 3 SKU en $38 + 30 + 27 = 95$.

Cuidado

Compras compra para 95, comercial promete 100: **doble plan**. La discusión se vuelve sobre “¿cuál número es el bueno?” en vez de sobre la decisión.

Implicancia operacional

La reconciliación impone **un solo número** coherente por nivel. Es gobernanza, no solo técnica.



Intermitencia y elección del nivel



El SKU intermitente es rebelde


Muchos ceros $\Rightarrow$ pronóstico por SKU muy **ruidoso**; bottom-up hereda esa varianza.

Estrategia

Pronosticar en la **familia** (con señal) y bajar al SKU por proporciones recientes (middle-out).

Idea clave

La presencia de SKU intermitentes **empuja hacia arriba** el nivel de pronóstico.



Python: bottom-up y top-down básicos




```
import pandas as pd
# fc_sku: DataFrame ancho con pronostico por SKU (columnas = SKU)
bottom_up = fc_sku.sum(axis=1) # total coherente por suma

prop = (hist_sku.mean() / hist_sku.mean().sum()) # proporciones historicas
top_down = pd.DataFrame({sku: fc_total * prop[sku] # reparte el total
                        for sku in fc_sku.columns})
# elegir el enfoque por validacion temporal POR NIVEL
```

Idea clave

No basta comparar el total: hay que evaluar el error **en cada nivel**.



Seleccionar el nivel de pronóstico




Preguntas guía


- ▶ ¿Dónde hay **señal** suficiente?
- ▶ ¿Qué nivel usa realmente la **decisión**?
- ▶ ¿Qué tan estable es el **mix**?

Heurística

Familias estables $\Rightarrow$ middle-out. SKU
muy intermitentes $\Rightarrow$ agregar y repartir.




Del pronóstico a la planificación de operaciones



Implicancia operacional

El pronóstico y su **incertidumbre** fijan el stock de seguridad y el nivel de servicio.




Jerarquía, inventarios y S&OP



- ▶ **S&OP:** concilia demanda (familias) con capacidad y finanzas; usa niveles **agregados**.
- ▶ **Inventarios:** el stock de seguridad depende de la **variabilidad** del pronóstico del SKU.
- ▶ **Compras / lead time:** el horizonte debe cubrir el **lead time**.
- ▶ **Planificación de familias:** agrega SKU en unidades planificables.

Idea clave

La jerarquía de productos **es** la jerarquía de decisiones de operaciones.



Puente: hacia la reconciliación óptima (Unidad 5)



La idea que viene

Toda reconciliación lineal se escribe


$$\tilde{y} = S P \hat{y}$$

S codifica la jerarquía; P combina la información de **todos** los niveles.


- ▶ Bottom-up y top-down son **casos** de P .
- ▶ **MinT** usa la covarianza de los errores: coherente y más preciso.

Idea clave

En el electivo/tópico generalizamos estos tres enfoques en un solo marco óptimo.




Caso guiado: de los datos a la recomendación



Salida del pipeline (categoría Bebidas, real)

Rolling origin: ETS 13,9 % vs SeasonalNaive 14,6 % $\Rightarrow$ **ETS**. Jerarquía (WAPE SKU): bottom-up 26,3 %, top-down **21,7 %**; ambos coherentes.


$\hookrightarrow$ *Replícalo:* scripts/pipeline_u1.py: los 6 pasos, ejecutable de principio a fin.



Errores frecuentes con jerarquías



- ▶ Evaluar solo el **total** y no el desempeño por nivel/SKU.
- ▶ Top-down con proporciones fijas ante **mix** cambiante.
- ▶ Pronosticar cada nivel por separado y quedar **incoherente**.
- ▶ Ignorar la **intermitencia** del SKU al elegir el nivel.
- ▶ Confundir estabilidad porcentual (arriba) con exactitud absoluta (abajo).



Cierre de la clase



Qué debe quedar claro

- ▶ Agregar estabiliza; el SKU decide.
- ▶ Bottom-up/top-down/middle-out y coherencia.
- ▶ La jerarquía conecta con S&OP e inventarios.

Checklist de interpretación

- ▶ ¿Qué nivel tiene señal?
- ▶ ¿Mis pronósticos son coherentes?
- ▶ ¿Evalué por nivel?

Actividad:

Para preparar la siguiente clase Preparar el Caso 1: diagnosticar la jerarquía del dataset y proponer una estrategia por nivel.

Puente a la evaluación

La Semana 5 es el **Caso 1**: pronóstico operacional y jerarquías (evaluación compartida con